Tema 1: Big Data

1. Big Data

¿Qué es el Big Data?

Grandes volúmenes de datos que son **difíciles de procesar y analizar** con herramientas tradicionales debido a su tamaño, complejidad y rapidez de generación.

La popularidad de Internet y las redes sociales han hecho que los usuarios de Internet sean a la vez consumidores y productores de contenido. Lo cual genera una gran cantidad de datos.

¿Para qué se usa Big Data?

- **Mejora en la toma de decisiones.** Análisis de grandes volúmenes de datos para identificar patrones, tendencias y hacer predicciones precisas. Ej: Predicción de demanda en empresas de retail.
- **Optimización de procesos empresariales.** Mejorar la eficiencia operativa y reducir costos. Ejemplo: Optimización de la cadena de suministro o logística.
- **Personalización de experiencias.** Para personalizar productos y servicios según las preferencias de los clientes. Ej: Recomendaciones de productos en plataformas como Amazon o Netflix.
- **Investigación y desarrollo.** Impulsa avances en investigación científica y tecnológica al procesar grandes cantidades de datos experimentales. Ej: Descubrimiento de nuevos medicamentos o terapias genéticas

Estadística

Es la ciencia que se encarga **de recolectar, analizar, interpretar y presentar datos**. Utiliza métodos matemáticos para inferir propiedades sobre una población a partir de una muestra, con el objetivo de entender patrones y tendencias.

- **Estadística descriptiva:** Nos ayuda a describir nuestros datos. Se apoya en el Análisis Exploratorio de Datos
- **Estadística inferencial:** Hacer predicciones sobre una población basándose en una muestra.

IA vs ML vs Estadística

- **Machine Learning:** utiliza técnicas estadísticas para extraer patrones de datos y mejorar los modelos con más experiencia (datos).
- **Big Data:** se utiliza como una fuente de datos masivos para aplicaciones tanto de estadística como de Machine Learning.
- **Inteligencia Artificial:** es el campo más amplio que abarca muchas tecnologías, incluyendo Machine Learning y Big Data, que le permiten mejorar y automatizar

2. Del Dato a la Información

¿Cómo funciona la pirámide DIKW?

Representa un proceso ascendente, donde **los datos se transforman en información, luego en conocimiento y finalmente en sabiduría**. Cada nivel construye sobre el anterior, y la sabiduría es el resultado de la integración de todos los niveles

- **Datos:** Cada registro de venta es un dato individual (fecha, producto, cantidad, precio).
- **Información:** Al analizar los datos, puedes generar informes que muestren las ventas totales por mes, los productos más vendidos o los clientes más recurrentes.
- **Conocimiento:** A partir de estos informes, puedes identificar tendencias en las ventas, predecir la demanda futura y ajustar tus estrategias de marketing.
- **Sabiduría:** Utilizando este conocimiento, puedes desarrollar nuevos productos, mejorar la experiencia del cliente y tomar decisiones estratégicas para el crecimiento de tu negocio.

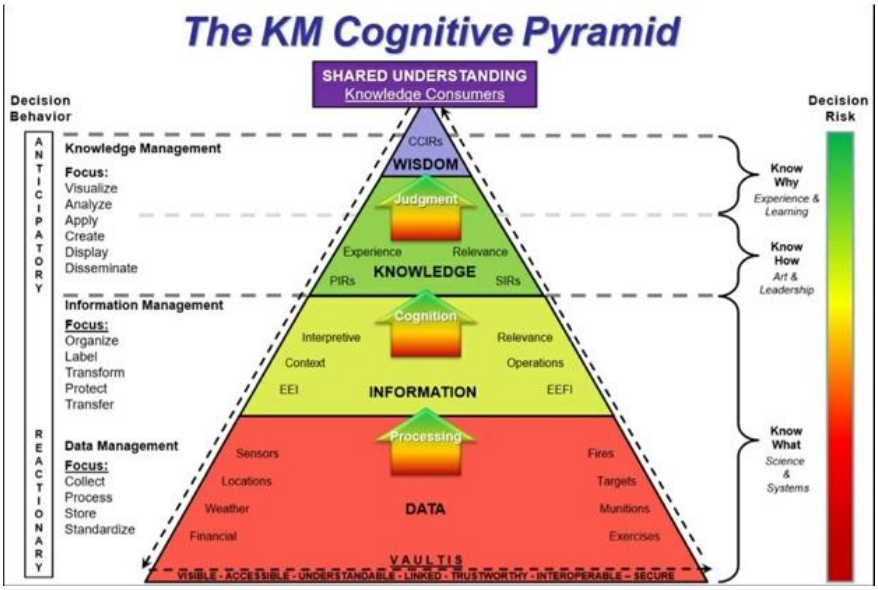

A medida que ascendemos en la pirámide nos enfrentamos con conceptos menos programables y susceptibles de ser manipulados mediante algoritmos.

2.1 Caracterización del Dato

Dato en cuanto al Tipo

- **Tipos simples:** Representan un **único valor**. Estos se dividen en lógicos, caracteres y numéricos, cada uno de ellos representado por un número de bits.
- **Tipos complejos:** Son el resultado de la **combinación de los tipos simples** y aparecen tipos compuestos, que representan un conjunto de valores a modo de estructura. Con tipos compuestos podemos representar la imagen de la matrícula de un coche, en forma de matriz de bits, etc.

Dato en cuanto al Formato

- **Datos estructurados:** Los datos se presentan en un **modelo o esquema organizativo**. Ejemplo: una base de datos SQL, donde las colecciones se hacen presentes mediante tablas y las relaciones como referencias. Por ejemplo: un cliente en una tabla puede estar almacenado como tipo compuesto en una tabla, constituyendo un registro y estará compuesto por un conjunto de datos simples.
- **Datos semiestructurados:** Estos datos no son estructurados, pero que **presentan cierta organización**. Por ejemplo: MIME (Multipurpose Internet Mail Extension), XML y JSON.
- **Datos no estructurados:** Se caracterizan por su **formato variable** y la **dificultad para almacenarlos** en bases de datos relacionales tradicionales. Ejemplo: Mensajes de Blog, Imágenes de redes sociales, Datos geoespaciales, Lecturas de sensores de una ciudad, Etc...

Dato en cuanto al Generador

- **Datos generados por personas:** Son los que más rápidamente están creciendo por el volumen de interacciones en las redes sociales y el comercio electrónico. Ejemplos: Información sobre nuestro día a día online, Evaluaciones online de productos, Blog y vídeos subidos por usuarios, Publicaciones en redes sociales, Texto en la red social X, Información recopilada de la apps móviles...
- **Datos generados por máquinas:** Información creada, capturada y transmitida por dispositivos, sensores y sistemas automatizados, sin intervención humana directa. Ejemplos: Lectura de sensores, Registros de transacciones comerciales online, Registros de accesos web, Datos generados por dispositivos IoT, Etc...

Dato en cuanto al Tamaño

El Impacto del Tamaño en el ANÁLISIS de DATOS:

- Complejidad del análisis.
- Necesidad de escalabilidad.
- Importancia de la visualización

Dato en cuanto al Rol

- **Datos maestros:** se refieren a un conjunto de información consistente y unificada sobre **entidades clave** de una organización. Estos datos son esenciales para las operaciones comerciales y se comparten entre diferentes áreas y sistemas.
  Características de los datos maestros:
  - Consistencia.
  - Uniformidad.
  - Centralización.
  - Actualización.

  Beneficios de los datos maestros:

  - Mejora de la calidad de los datos.
  - Facilitación de la integración de datos.
  - Obtención de una visión unificada del negocio.
  - Toma de decisiones más informada.

  Ejemplos: Clientes, Productos, Proveedores, Empleados, Ubicaciones

- **Datos operacionales:** En el contexto empresarial, se refieren a la información generada por las **operaciones diarias del negocio**.
  Ejemplos: Datos de transacciones de clientes, Datos de inventario, Datos de navegación web.

- **Datos externos:** datos generados y recopilados **fuera del propio negocio**, pero que tienen relación él, siendo susceptibles de **influir y aportar valor**. Fuentes:
    - Redes sociales
    - Blogs.
    - Sitios webs.
    - Dispositivos móviles.
    - Información financiera.
- **Datos analíticos:** Aquí ya se habla de información en lugar de datos. El dato analítico se genera a partir de los **datos operacionales dentro del contexto de los datos maestros**, denominados **dimensiones**, a lo largo de una perspectiva temporal.

Dato en cuanto a la Latencia

Se refiere al tiempo que transcurre **entre la solicitud de un dato y su disponibilidad para su uso**. Es un factor crítico en muchas aplicaciones, especialmente en aquellas que requieren respuestas en tiempo real o procesamiento de alta frecuencia

- **Datos en tiempo real:** son aquellos que se procesan y **analizan a medida que se generan**, permitiendo tomar **decisiones y acciones inmediatas**. El procesamiento en tiempo real es una característica inherente a los **datos operacionales.** Ejemplos: Monitorización de seguridad en redes, Comercio electrónico, Redes sociales, Sistemas de transporte, ETC...

  Beneficios de los datos en tiempo real:
    - Toma de decisiones más rápida e informada.
    - Mejor experiencia del cliente.
    - Mayor eficiencia operativa.
    - Innovación.

- **Datos en lotes:** Los datos son almacenados en un lote (batch) cuando son recibidos, permaneciendo así durante un periodo de tiempo o hasta que alcancen un volumen determinado. Por ejemplo, una empresa puede procesar las transacciones de ventas del día al final del día, o los datos de sensores cada hora.

  Ventajas:
  - Eficiencia para grandes volúmenes de datos.
  - Simplificación de la infraestructura.

  Desventajas:
  - Mayor latencia.
  - Menor flexibilidad.

Dato en cuanto a la Sensibilidad

Son los datos clasificados en términos de **privacidad e intimidad**. Esto marca quien accede a estos datos y durante cuánto tiempo, estableciéndose también las condiciones en que deben ser almacenados.

Las empresas suelen categorizar estos datos en cuanto a su sensibilidad y acceso, pero además estas tienen en cuenta tanto **datos recogidos de las interacciones con los clientes y proveedores, como aquellos generados por el propio negocio**.

Varían de un país a otro en función de las regulaciones que se apliquen:

- GDPR.
- SOC2.
- HIPAA.
- PCI SSC.

Hay tres clases de datos en términos del riesgo que supone su manipulación indebida:

- Riesgo alto.
- Riesgo medio.
- Riesgo bajo.

Riesgo bajo	Riesgo medio	Riesgo alto
• Ofertas de empleo. • Nota de prensa. • Material de marketing aprobado para uso público	• Identificadores internos de empleados • Datos de desarrollo, investigación y patentes no publicadas. • Contenidos con propiedad intelectual licenciada de tercero o restringida por contrato. • Datos de recursos humanos relacionados con los empleados.	• Identificadores personales (números de la Seguridad Social, DNI, pasaporte) • Contraseñas y claves de acceso a sistemas, aplicaciones, etc. • Información identificable sobre salud o pólizas. • Números de tarjetas de crédito o débito.

3. Roles

Chief Data Officer (CDO)

Es responsable de maximizar el valor estratégico de los datos en una organización. A través de la gobernanza y explotación eficiente de los datos, el CDO impulsa la toma de decisiones basada en datos.

Además, se encarga de la calidad de los datos, la seguridad y alineación con la estrategia de negocio.

Gobierno del dato

Es el **conjunto de políticas, procedimientos y estándares** que aseguran la **calidad, seguridad y uso adecuado de los datos** en una organización. Su objetivo es garantizar que los datos sean **consistentes, confiables y accesibles** para su uso en la toma de decisiones. Sus roles son:

- **Data Owner:** es la persona o equipo responsable de los datos en su ciclo de vida. Establece reglas sobre **cómo deben gestionarse y es responsable de su calidad y seguridad**. Tiene una visión estratégica de los datos dentro de su dominio.
- **Data Steward**: es el encargado operativo de **garantizar que las políticas de gobierno de datos se cumplan**. Se asegura de que los datos sean precisos, estén disponibles y cumplan con los estándares definidos por los Data Owners y el equipo de gobernanza.

Arquitectura de datos

Para diseñar, implementar y mantener la infraestructura que soporta el manejo de datos. Sus roles son:

- **Data Architect**: Diseña la estructura general de los sistemas de datos. Define cómo se almacenarán, accederán y procesarán los datos en la organización. Su enfoque es tanto estratégico como técnico.

  Responsabilidades: Diseñar modelos de datos, seleccionar tecnologías y establecer políticas de almacenamiento y acceso.

- **Cloud Architect:** Diseña y gestiona la arquitectura de datos en entornos en la nube. Selecciona las plataformas de nube (AWS, Azure, GCP) y define cómo los datos serán almacenados, protegidos y procesados en estos entornos.

  Responsabilidades: Configurar infraestructuras en la nube, garantizar la escalabilidad y la seguridad de los datos

Data Engineer

El Ingeniero de Datos (Data Engineer) es responsable de **construir y mantener la infraestructura que permite el flujo, almacenamiento y procesamiento eficiente de datos dentro de una organización**. Su trabajo principal es crear **pipelines de datos**. Sus responsabilidades son:

- **Diseño y creación de pipelines de datos:** Implementa flujos de trabajo que capturan, procesan y transforman datos desde diversas fuentes hacia un destino, como un Data Warehouse o Data Lake.
- **Optimización del rendimiento:** Se asegura de que los pipelines y las infraestructuras de datos funcionen de manera eficiente, minimizando tiempos de procesamiento y maximizando el rendimiento

- **Garantizar la calidad de los datos:** Implementa procesos para limpiar, validar y transformar los datos para asegurar su calidad antes de que lleguen a los analistas o científicos de datos.
- **Gestión de herramientas y tecnologías:** Selecciona y trabaja con tecnologías como Hadoop, Spark, Kafka, bases de datos NoSQL, entre otras, para el procesamiento masivo de datos

Data Scientist

Un Data Scientist es un profesional que **analiza grandes volúmenes de datos** para obtener insights valiosos que ayuden en la toma de decisiones estratégicas. Combina conocimientos en estadística, matemáticas y programación para crear modelos predictivos, analizar patrones y resolver problemas de negocio mediante datos.

Otros roles

- **Machine Learning Engineer:** Especializado en diseñar, construir y desplegar modelos de machine learning en producción.
- **Data Governance Manager:** Responsable de implementar y supervisar las políticas de gobierno de datos.
- **Data Visualization Specialist:** Enfocado en crear visualizaciones efectivas para comunicar insights de datos.
- **Data Analyst:** Fundamental para transformar datos en insights accionables. Es el rol más directamente relacionado con el análisis y la generación de informes.
- **Data Translator:** Crucial en organizaciones donde hay una brecha significativa entre equipos técnicos y de negocio. Facilita la alineación y la comunicación efectiva.
- **Business Owner:** Vital para asegurar que las iniciativas de datos estén alineadas con las metas estratégicas del negocio y para proporcionar dirección y recursos.

4. Etapas de análisis en la exploración de la información

Analítica descriptiva

Proporciona información sobre el rendimiento pasado del negocio y su contexto. Este tipo de análisis se vale de informes, de cuadros de mando (dashboards) que permiten al usuario consultar y navegar por la información en modo autoservicio. Responde a preguntas como:

- Cuál fue el número de piezas defectuosas en cada una de las fábricas durante el último trimestre.
- Cómo ha variado la rentabilidad promedio por metro cuadrado de las tiendas respecto al último año.
- Qué relación existe entre los días de lluvia y el incremento en la venta de paraguas.

Analítica prescriptiva

Tiene un enfoque más operativo y de proceso, ya que busca detallar la mejor solución para una situación determinada. Por ejemplo:

- Organizar los turnos y las rotaciones de las tripulaciones en una compañía aérea teniendo en cuenta restricciones operativas y laborales.
- Establecer las ubicaciones más adecuadas para situar una serie de centros logísticos con el fin de abastecer los puntos de venta los más rápido posible, incurriendo en los mínimos costes.
- Definir la estrategia más adecuada para el petróleo, considerando los niveles de producción en cada momento, la demanda y la situación geopolítica.

Analítica predictiva

Se basa en el **descubrimiento de patrones, tendencias y relaciones** que permiten explicar un comportamiento a partir de datos históricos con el fin de anticiparse a él en el futuro.

Analítica cognitiva

Refleja el estado del arte de la tecnología en cuanto al procesamiento y el análisis de la información. La inteligencia artificial, a través de los sistemas simbólicos y del aprendizaje profundo (deep learning) con el procesamiento del leguaje natural (Language Processing), el reconocimiento del habla o la clasificación de imágenes.

El objetivo es desarrollar sistemas con capacidad para entender, razonar e interactuar emulando a los seres humanos. Por ejemplo:

- Revelando patrones y relaciones entre los datos que son difíciles de detectar, sugiriendo nuevos cruces de información.
- Recomendando las mejores formas de representar y visualizar los datos, interpretando su significado y contexto.
- Respondiendo a preguntas en lenguaje natural, de forma clara y concisa, acelerando la navegación sobre los datos

5. Almacenamiento

Bases de datos

En Big Data se tiende a replicar la información, ya que **importa más el acceso al dato más que su almacenaje**, ya que esto último suele ser más barato. En la práctica las ETL's, se hacen con JOIN de distintas tablas quedando una tabla mucho más grande.

Tipos:

- **NoSQL:** ofrecen modelos de esquema **flexibles** y **no dependen de tablas estructuradas ni de consultas SQL**. Están diseñadas para gestionar datos distribuidos a gran escala con distintos formatos.
    - **Document store:** Almacena documentos formato JSON
    - **Clave valor:** Los datos se guardan como pares clave valor
    - **Columnar:** Almacena el contenido en columnas en lugar de filas, diseñado para una eficiciencia alta de lectura/escritura
    - **Grafos:** Se centran en las relaciones entre puntos de datos utilizando estructuras gráficas de nodos y aristas.

- **Series Temporales:** Para manejar datos de series temporales en las que se recopilan puntos de datos a lo largo del tiempo. Estas bases de datos están optimizadas para **leer y escribir secuencias de datos**, generalmente **con una marca de tiempo**. Usado en
    - IoT
    - Datos financieros
    - Monitorización de sistemas

- **De vectores:** Es una base de datos que puede almacenar vectores (listas de números de longitud fija) junto con otros elementos de datos. Generalmente implementan el algoritmo ANN o kNN para que uno pueda buscar en la base de datos con un vector de consulta para recuperar los registros de base de datos coincidentes más cercanos.